



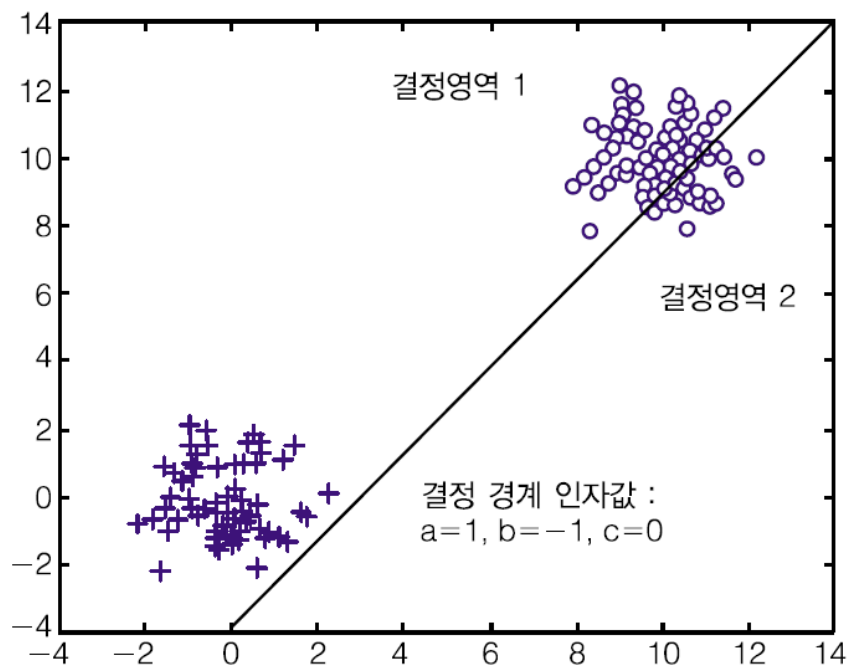
# 01\_선형 분류기

## ❖ 선형 분류기(linear classifier)


$$g(\mathbf{x}, \mathbf{y}) = a\mathbf{x} + b\mathbf{y} + c$$

※ a, b, c는 가중치(weights)

가중치의 개수는(특징 벡터의 차원 수+1)



(a) 학습 전의 결정 경계



(b) 학습 후의 결정 경계



## ❖ 판별식 가중치 결정

- 판별식을 정의하는데 중요한 파라미터 : 가중치벡터  $w$
- 라벨이 정해진  $N$  차원의 특징벡터집합인 학습 데이터로부터 최소의 분류 오차를 생성하는 최적의 가중치 파라미터를 찾음

$$g(\mathbf{x}, \mathbf{y}) = \langle \mathbf{w}, \mathbf{x} \rangle + w_0$$

$$= \sum_{i=1}^n w_i x_i + w_0$$

- $\mathbf{w} = (w_1, w_2, \dots, w_n)^T$  는 가중치 벡터를 의미한다
- $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$  는 입력 벡터다.



## ❖ 판별식 가중치 결정

- 가중치 벡터  $w$ 는 판별식을 결정하는 데 중요한 파라미터다. 그렇다면 이 파라미터를 어떻게 학습할 것인가?
- 학습 데이터가 클래스 라벨이 붙은  $N$ 차원의 특징 벡터 집합일 때, 분류오차를 최소로 하는 **최적의 가중치 파라미터를 찾아야** 한다.
- 이 가중치를 찾는 여러 가지 접근법이 있는데, 대부분 주어진 학습 집합에서 **분류 오차를 최소화**하는 방식을 채택하고 있다.

## ❖ 결정 경계


- 두 개의 클래스에 대한 문제에서는 결정 경계(decision boundary)로 선형 판별식 한 개가 필요하다.
- 그럼 3개 이상의 클래스를 분류하려면, 몇 개의 선형 판별식이 필요한가?



# 01\_선형 분류기


## ❖ 다중 클래스 결정 경계

- 각 클래스가 단일한 판별식에 의해 결정되는 경우



[그림 6-2] 단일한 판별식

- 판별식이 클래스의 쌍으로 결정되는 경우



[그림 6-3] 쌍으로 분류되는 판별식



# 01\_선형 분류기

- 3개의 클래스와 3개의 판별식이 주어진 경우

만약  $d_1(x, y) > d_2(x, y)$ 고  $d_1(x, y) > d_3(x, y)$ 면, 클래스 1로 결정한다.

만약  $d_2(x, y) > d_1(x, y)$ 고  $d_2(x, y) > d_3(x, y)$ 면, 클래스 2로 결정한다.

만약  $d_3(x, y) > d_2(x, y)$ 고  $d_3(x, y) > d_1(x, y)$ 면, 클래스 3으로 결정한다.



## 02\_이차 분류기

- 이차 분류기: 판별함수가 가우시안 분포를 이룬다고 가정할 경우
- 선형 분류기: 판별식은 2차원에서는 직선형태, 3차원에서는 평면형태
- 최소-거리 분류기 혹은 마할나노비스(mahalanobis) 분류기 조건
  - 모두 가우시안 분포에 따르며
  - 같은 공분산 값을 가지며
  - 사전 확률이 같을 경우 사용하는 방법
- 유클리디안 거리 분류기 조건
  - 모두 가우시안 분포에 따르며
  - 항등 행렬에 비례하는 동일한 공분산 값을 가지며
  - 사전 확률이 같을 경우

Case 1:  $\Sigma_i = \sigma^2 \mathbf{I}$

Case 2:  $\Sigma_i = \Sigma$  ( $\Sigma$ : 대각행렬)

Case 3:  $\Sigma_i = \Sigma$  ( $\Sigma$ : 비대각행렬)

Case 4:  $\Sigma_i = \sigma_i^2 \mathbf{I}$

Case 5:  $\Sigma_i \neq \Sigma_j$  (일반형)



### ❖ 가우시안 확률밀도함수의 일반식

$$f_x(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp \left[ -\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \right]$$

$$\begin{aligned} g_i(\mathbf{x}) = P(\omega_i | \mathbf{x}) &= \frac{P(\mathbf{x} | \omega_i) P(\omega_i)}{P(\mathbf{x})} \\ &= \frac{1}{(2\pi)^{n/2} |\Sigma_i|^{1/2}} \exp \left[ -\frac{1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) \right] P(\omega_i) \frac{1}{P(\mathbf{x})} \end{aligned}$$

$$g_i(\mathbf{x}) = |\Sigma_i|^{-1/2} \exp \left[ -\frac{1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) \right] P(\omega_i)$$

$$g_i(\mathbf{x}) = -\frac{1}{2} (\mathbf{x} - \mu_i)^T \Sigma_i^{-1} (\mathbf{x} - \mu_i) - \frac{1}{2} \log(|\Sigma_i|) + \log(P(\omega_i))$$



### ❖ 데이터에 대한 통계적인 공분산 행렬의 종류

Case 1:  $\Sigma_i = \sigma^2 \mathbf{I}$

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \mu_i)^T (\sigma^2 \mathbf{I})^{-1} (\mathbf{x} - \mu_i) - \frac{1}{2} \log(|\sigma^2 \mathbf{I}|) + \log(P(\omega_i))$$

$$= -\frac{1}{2\sigma^2} (\mathbf{x} - \mu_i)^T (\mathbf{x} - \mu_i) - \frac{1}{2} N \log(\sigma^2) + \log(P(\omega_i))$$

$$= -\frac{1}{2\sigma^2} (\mathbf{x} - \mu_i)^T (\mathbf{x} - \mu_i) + \log(P(\omega_i))$$

$$g_i(\mathbf{x}) = -\frac{1}{2\sigma^2} (\mathbf{x} - \mu_i)^T (\mathbf{x} - \mu_i) + \log(P(\omega_i))$$

$$= -\frac{1}{2\sigma^2} (\mathbf{x}^T \mathbf{x} - 2\mu_i^T \mathbf{x} + \mu_i^T \mu_i) + \log(P(\omega_i))$$





## 02\_이차 분류기

### ❖ 데이터에 대한 통계적인 공분산 행렬의 종류

Case 1:  $\Sigma_i = \sigma^2 \mathbf{I}$

$$g_i(\mathbf{x}) = -\frac{1}{2\sigma^2}(-2\mu_i^T \mathbf{x} + \mu_i^T \mu_i) + \log(P(\omega_i)) = \mathbf{w}_i^T \mathbf{x} + w_{i0}$$

$$\ast \left\{ \begin{array}{l} \mathbf{w}_i = \frac{\mu_i}{\sigma^2} \\ w_{i0} = -\frac{1}{2\sigma^2} \mu_i^T \mu_i + \log(P(\omega_i)) \end{array} \right.$$

$$g_i(\mathbf{x}) = -\frac{1}{2\sigma^2}(\mathbf{x} - \mu_i)^T(\mathbf{x} - \mu_i)$$



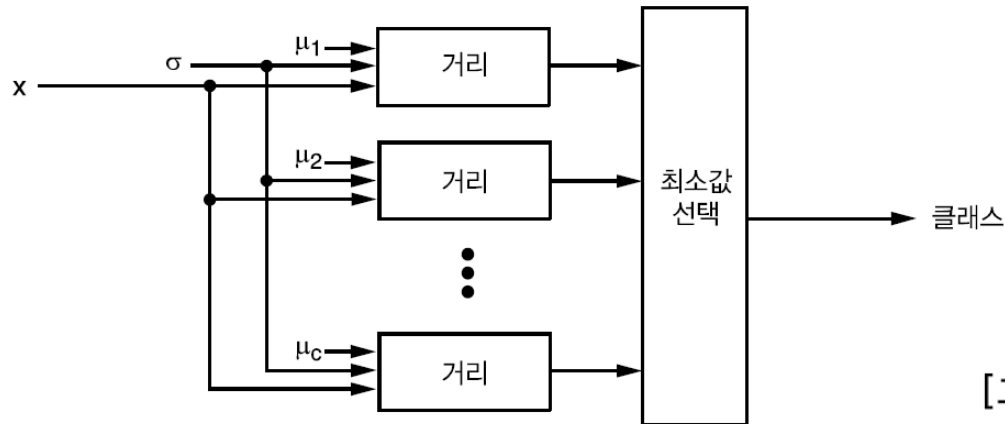
### ❖ 데이터에 대한 통계적인 공분산 행렬의 종류

**예** 다음과 같은 클래스 평균과 공분산 행렬에 따르며, 2차원 특징 벡터로 이루어진 3개의 클래스에 대한 결정 경계를 계산한다(사전 확률은 동일하다고 가정).



$$\begin{aligned}\mu_1 &= \begin{bmatrix} 3 & 2 \end{bmatrix}^T & \mu_2 &= \begin{bmatrix} 7 & 4 \end{bmatrix}^T & \mu_3 &= \begin{bmatrix} 2 & 5 \end{bmatrix}^T \\ \Sigma_1 &= \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} & \Sigma_2 &= \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} & \Sigma_3 &= \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}\end{aligned}$$



## ❖ 데이터에 대한 통계적인 공분산 행렬의 종류



[그림 6-4] 최근접 평균 분류기



[그림 6-5] Case 1의 특징 벡터의 분포와 결정 경계



### ❖ 데이터에 대한 통계적인 공분산 행렬의 종류

Case 2:  $\Sigma_i = \Sigma$  ( $\Sigma$ : 대각행렬)

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) - \frac{1}{2} \log(|\boldsymbol{\Sigma}_i|) + \log(P(\omega_i))$$

$$= -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \begin{bmatrix} \sigma_1^{-2} & & \\ & \ddots & \\ & & \sigma_N^{-2} \end{bmatrix}^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \frac{1}{2} \log \left( \begin{vmatrix} \sigma_1^{-2} & & \\ & \ddots & \\ & & \sigma_N^{-2} \end{vmatrix} \right) + \log(P(\omega_i))$$

$$= -\frac{1}{2} \sum_{k=1}^N \frac{(\mathbf{x}[k] - \mu_i[k])^2}{\sigma_k^2} - \frac{1}{2} \log \prod_{k=1}^N \sigma_k^2 + \log(P(\omega_i))$$

$$= -\frac{1}{2} \sum_{k=1}^N \frac{\mathbf{x}[k]^2 - 2\mathbf{x}[k]\mu_i[k] + \mu_i[k]^2}{\sigma_k^2} - \frac{1}{2} \log \prod_{k=1}^N \sigma_k^2 + \log(P(\omega_i))$$



### ❖ 데이터에 대한 통계적인 공분산 행렬의 종류



**예** 다음과 같은 클래스 평균과 공분산 행렬에 따르면, 2차원 특징 벡터로 이루어진 3개의 클래스에 대한 결정 경계를 계산한다(사전 확률은 동일하다고 가정).

$$\begin{aligned}\mu_1 &= \begin{bmatrix} 3 & 2 \end{bmatrix}^T & \mu_2 &= \begin{bmatrix} 5 & 4 \end{bmatrix}^T & \mu_3 &= \begin{bmatrix} 2 & 5 \end{bmatrix}^T \\ \Sigma_1 &= \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix} & \Sigma_2 &= \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix} & \Sigma_3 &= \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}\end{aligned}$$



### ❖ 데이터에 대한 통계적인 공분산 행렬의 종류

$$g_i(\mathbf{x}) = -\frac{1}{2} \sum_{k=1}^N \frac{-2\mathbf{x}[k]\mu_i[k] + \mu_i[k]^2}{\sigma_k^2} - \frac{1}{2} \log \prod_{k=1}^N \sigma_k^2 + \log(P(\omega_i))$$



[그림 6-6] Case 2의 특징 벡터의 분포와 결정 경계



### ❖ 데이터에 대한 통계적인 공분산 행렬의 종류

Case 3:  $\Sigma_i = \Sigma$  ( $\Sigma$ : 비대각행렬)


$$\begin{aligned} g_i(\mathbf{x}) &= -\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma_i^{-1}(\mathbf{x} - \mu_i) - \frac{1}{2} \log(|\Sigma_i|) + \log(P(\omega_i)) \\ &= -\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma^{-1}(\mathbf{x} - \mu_i) - \frac{1}{2} \log(|\Sigma|) + \log(P(\omega_i)) \end{aligned}$$

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \mu_i)^T \Sigma^{-1}(\mathbf{x} - \mu_i) + \log(P(\omega_i))$$



### ❖ 마할라노비스 거리

$$\|x - y\|_{\Sigma^{-1}}^2 = (x - y)^T \Sigma^{-1} (x - y)$$



[그림 6-7] 마할라노비스 거리





### ❖ 마할라노비스 거리

$$\begin{aligned} g_i(\mathbf{x}) &= -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) + \log(P(\omega_i)) \\ &= -\frac{1}{2}(\mathbf{x}^T \boldsymbol{\Sigma}^{-1} \mathbf{x} - 2\boldsymbol{\mu}_i^T \boldsymbol{\Sigma}^{-1} \mathbf{x} + \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_i) + \log(P(\omega_i)) \end{aligned}$$

$$g_i(\mathbf{x}) = -\frac{1}{2}(-2\boldsymbol{\mu}_i^T \boldsymbol{\Sigma}^{-1} \mathbf{x} + \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_i) + \log(P(\omega_i))$$

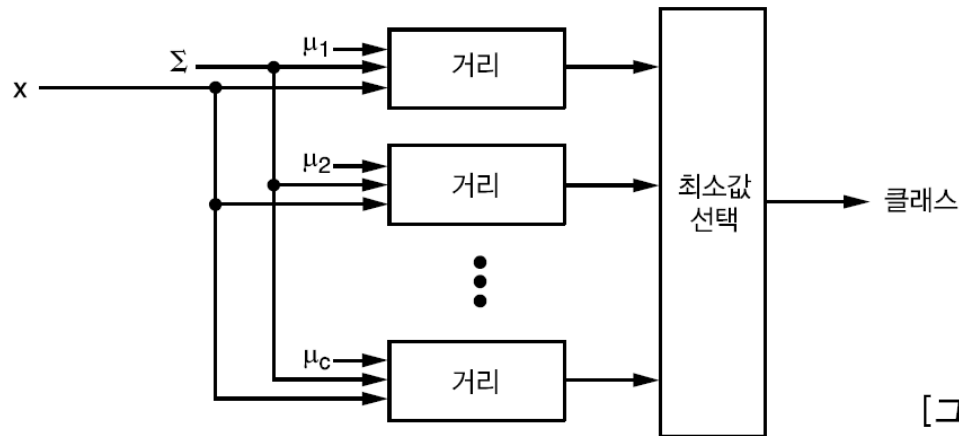
$$\mathbf{g}_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} + w_{i0}$$

$$\ast \begin{cases} \mathbf{w}_i = \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_i \\ w_{i0} = -\frac{1}{2} \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_i + \log(P(\omega_i)) \end{cases}$$

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_i)$$





## ❖ 마할라노비스 거리



$$\mu_1 = \begin{bmatrix} 3 & 2 \end{bmatrix}^T \quad \mu_2 = \begin{bmatrix} 5 & 4 \end{bmatrix}^T \quad \mu_3 = \begin{bmatrix} 2 & 5 \end{bmatrix}^T$$
$$\Sigma_1 = \begin{bmatrix} 1 & 0.7 \\ 0.7 & 2 \end{bmatrix} \quad \Sigma_2 = \begin{bmatrix} 1 & 0.7 \\ 0.7 & 2 \end{bmatrix} \quad \Sigma_3 = \begin{bmatrix} 1 & 0.7 \\ 0.7 & 2 \end{bmatrix}$$

[그림 6-8] 마할라노비스 분류기



[그림 6-9] Case 3의 특징 벡터의 분포와 결정 경계



### ❖ 데이터에 대한 통계적인 공분산 행렬의 종류

Case 4:  $\Sigma_i = \sigma_i^2 \mathbf{I}$

$$\begin{aligned} g_i(\mathbf{x}) &= -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) - \frac{1}{2} \log(|\Sigma_i|) + \log(P(\omega_i)) \\ &= -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \sigma_i^{-2}(\mathbf{x} - \boldsymbol{\mu}_i) - \frac{1}{2} N \log(\sigma_i^2) + \log(P(\omega_i)) \end{aligned}$$





## 02\_이차 분류기

### ❖ 데이터에 대한 통계적인 공분산 행렬의 종류

Case 4:  $\Sigma_i = \sigma_i^2 \mathbf{I}$

$$\begin{aligned} \mu_1 &= \begin{bmatrix} 3 & 2 \end{bmatrix}^T & \mu_2 &= \begin{bmatrix} 5 & 4 \end{bmatrix}^T & \mu_3 &= \begin{bmatrix} 2 & 5 \end{bmatrix}^T \\ \Sigma_1 &= \begin{bmatrix} 0.5 & 0 \\ 0 & 0.5 \end{bmatrix} & \Sigma_2 &= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} & \Sigma_3 &= \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} \end{aligned}$$






## 02\_이차 분류기

### ❖ 데이터에 대한 통계적인 공분산 행렬의 종류

Case 4:  $\Sigma_i = \sigma_i^2 \mathbf{I}$



[그림 6-10] Case 4의 특징 벡터의 분포와 결정 경계



### ❖ 데이터에 대한 통계적인 공분산 행렬의 종류

Case 5:  $\Sigma_i \neq \Sigma_j$  (일반형)

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) - \frac{1}{2} \log(|\boldsymbol{\Sigma}_i|) + \log(P(\omega_i))$$

$$g_i(\mathbf{x}) = \mathbf{x}^T \mathbf{W}_i \mathbf{x} + \mathbf{w}_i^T \mathbf{x} + w_{i0}$$

$$\times \begin{cases} \mathbf{W}_i = -\frac{1}{2} \boldsymbol{\Sigma}_i^{-1} \\ \mathbf{w}_i = \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i \\ w_{i0} = -\frac{1}{2} \boldsymbol{\mu}_i^T \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i - \frac{1}{2} \log(|\boldsymbol{\Sigma}_i|) + \log(P(\omega_i)) \end{cases}$$







## 02\_이차 분류기

### ❖ 데이터에 대한 통계적인 공분산 행렬의 종류

Case 5:  $\Sigma_i \neq \Sigma_j$  (일반형)

$$\begin{aligned} \mu_1 &= \begin{bmatrix} 3 & 2 \end{bmatrix}^T & \mu_2 &= \begin{bmatrix} 5 & 4 \end{bmatrix}^T & \mu_3 &= \begin{bmatrix} 2 & 5 \end{bmatrix}^T \\ \Sigma_1 &= \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix} & \Sigma_2 &= \begin{bmatrix} 1 & -1 \\ -1 & 7 \end{bmatrix} & \Sigma_3 &= \begin{bmatrix} 0.5 & 0.5 \\ 0.5 & 3 \end{bmatrix} \end{aligned}$$

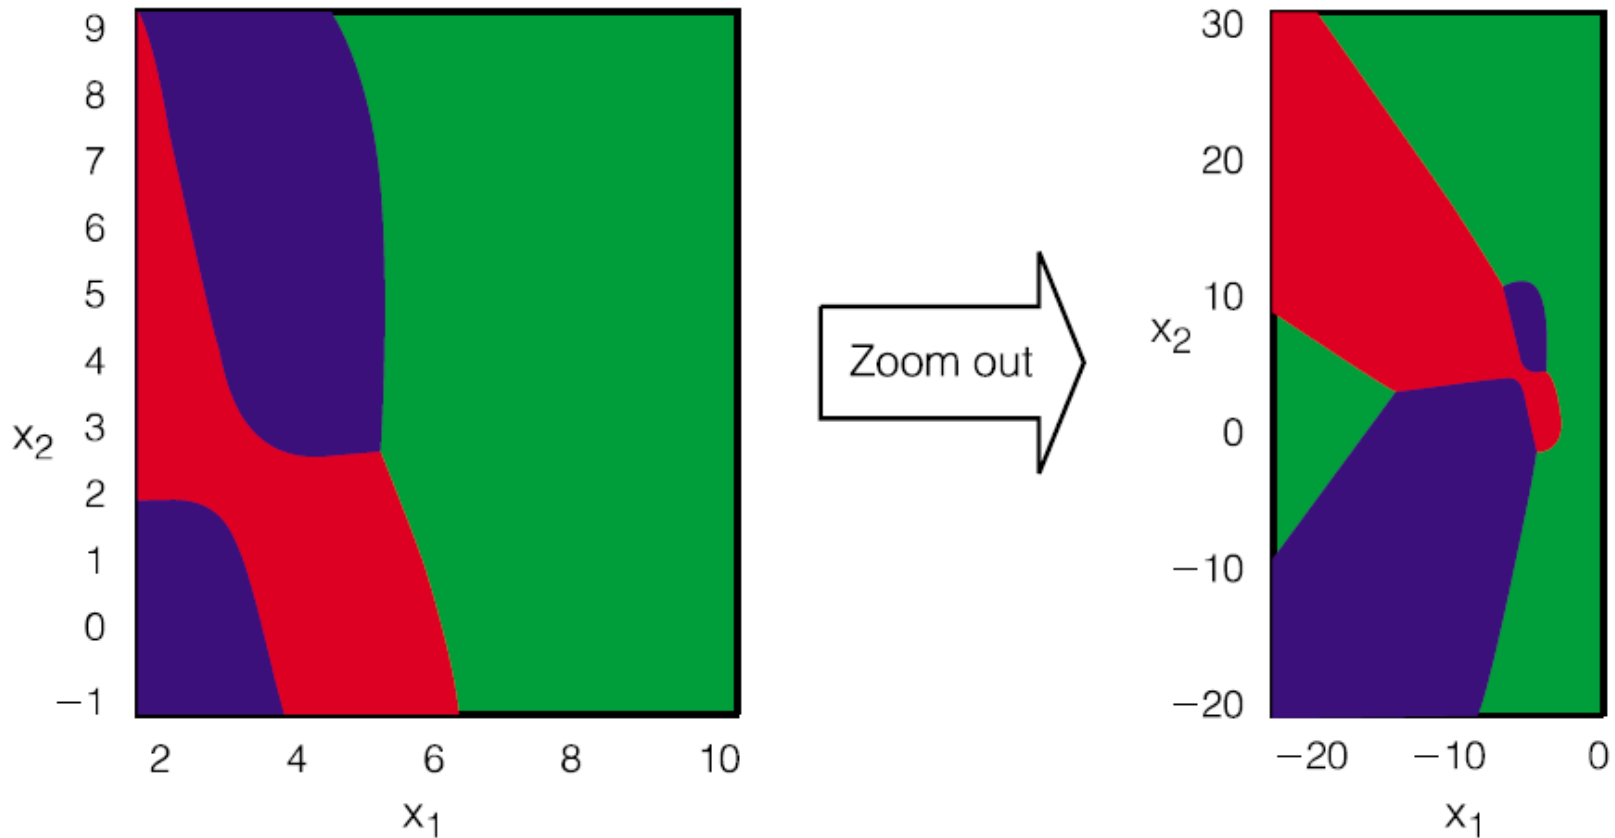




## 02\_이차 분류기

### ❖ 데이터에 대한 통계적인 공분산 행렬의 종류

Case 5:  $\Sigma_i \neq \Sigma_j$  (일반형)



[그림 6-11] Case 5의 특징 벡터의 분포와 결정 경계





## 02\_이차 분류기

### 예제 6-1

3차원 특징 벡터 집합에서 정의되는 다음과 같은 가우시안 파라미터로 이루어진 클래스  $\omega_1$ ,  $\omega_2$ 에 대한 선형 판별함수를 유도하고, 특징 벡터  $\mathbf{x}_u = [0.1 \ 0.7 \ 0.8]^T$ 가 어느 클래스에 속하는지 결정하시오.

$$\boldsymbol{\mu}_1 = [0 \ 0 \ 0]^T; \boldsymbol{\mu}_2 = [1 \ 1 \ 1]^T; \Sigma_1 = \Sigma_2 = \begin{bmatrix} 1/4 & 0 & 0 \\ 0 & 1/4 & 0 \\ 0 & 0 & 1/4 \end{bmatrix}; p(\omega_2) = 2p(\omega_1)$$

▷▷ 풀이

선형 판별함수  $g_1(\mathbf{x})$ ,  $g_2(\mathbf{x})$ 는 다음과 같다.

$$g_i(\mathbf{x}) = -\frac{1}{2\sigma^2}(\mathbf{x} - \boldsymbol{\mu}_i)^T(\mathbf{x} - \boldsymbol{\mu}_i) + \log P(\omega_i) = -\frac{1}{2} \begin{bmatrix} \mathbf{x} - \boldsymbol{\mu}_x \\ \mathbf{x} - \boldsymbol{\mu}_y \\ \mathbf{x} - \boldsymbol{\mu}_z \end{bmatrix}^T \begin{bmatrix} 4 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 4 \end{bmatrix} \begin{bmatrix} \mathbf{x} - \boldsymbol{\mu}_x \\ \mathbf{x} - \boldsymbol{\mu}_y \\ \mathbf{x} - \boldsymbol{\mu}_z \end{bmatrix} + \log P(\omega_i)$$



## 02\_이차 분류기

$$g_1(\mathbf{x}) = -\frac{1}{2} \begin{bmatrix} \mathbf{x}-0 \\ \mathbf{x}-0 \\ \mathbf{x}-0 \end{bmatrix}^T \begin{bmatrix} 4 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 4 \end{bmatrix} \begin{bmatrix} \mathbf{x}-0 \\ \mathbf{x}-0 \\ \mathbf{x}-0 \end{bmatrix} + \log \frac{1}{3}; \quad g_2(\mathbf{x}) = -\frac{1}{2} \begin{bmatrix} \mathbf{x}-1 \\ \mathbf{x}-1 \\ \mathbf{x}-1 \end{bmatrix}^T \begin{bmatrix} 4 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 4 \end{bmatrix} \begin{bmatrix} \mathbf{x}-1 \\ \mathbf{x}-1 \\ \mathbf{x}-1 \end{bmatrix} + \log \frac{2}{3}$$

$$g_1(\mathbf{x}) \underset{\omega_2}{\overset{\omega_1}{>}} g_2(\mathbf{x}) \Rightarrow -2(\mathbf{x}_1^2 + \mathbf{x}_2^2 + \mathbf{x}_3^2) + \log \frac{1}{3} \underset{\omega_2}{\overset{\omega_1}{>}} -2((\mathbf{x}_1-1)^2 + (\mathbf{x}_2-1)^2 + (\mathbf{x}_3-1)^2) + \log \frac{2}{3}$$

$$\mathbf{x}_1 + \mathbf{x}_2 + \mathbf{x}_3 \underset{\omega_2}{\overset{\omega_1}{<}} \frac{6 - \log 2}{4} = 1.32$$

테스트 데이터  $\mathbf{x}_u = [0.1 \quad 0.7 \quad 0.8]^T$  는 다음과 같다.

$$0.1 + 0.7 + 0.8 = 1.6 \underset{\omega_2}{\overset{\omega_1}{<}} 1.32 \Rightarrow \mathbf{x}_u \in \omega_2$$