

MACHINE 기계 학습 LEARNING

오일석 지음

10. 확률 그래피컬 모델

PREVIEW

■ 확률 추론 문제

- 흡연 환자의 엑스레이 진단에서 양성이 나타났을 때 폐암일 확률은?
- 한국은행이 기준금리를 올렸고 S전자의 1분기 실적이 양호일 때 S전자의 주식이 오를 확률은?

→답을 구할 수 있다면 매우 유용


■ 확률 그래피컬 모델 probabilistic graphical model

- 엑스레이, 흡연, 폐암을 확률변수로 정의하고 이들의 상호작용을 그래프로 표현하고, 그래프에서 확률 추론 수행
- 대표적 모델
 - 베이지안 네트워크
 - 마르코프 랜덤필드


10.1.1 그래프 표현

■ 그래프 표현

- 예, 흡연 환자의 엑스레이 진단에서 양성이 나타났을 때 폐암일 확률은?
 - 주요 요인 엑스레이, 흡연, 폐암을 확률변수로 뽑아 노드로 취함 (x_1, x_2, x_3)
 - 인과관계는 에지로 표현 (e_1, e_2)
- 그래프는 확률변수의 상호작용을 표현하는 뼈대
- 뼈대에 확률을 부여하면 확률 그래피컬 모델이 됨



(a) 베이저안 네트워크(방향 그래프)




(b) 마르코프 랜덤필드(무방향 그래프)

그림 10-1 확률 그래피컬 모델


10.1.1 그래프 표현

■ 대표적인 모델

- 베이저안 네트워크 Bayesian network
 - **인과관계**를 나타내기 위해 방향 에지를 사용
- 마르코프 랜덤필드
 - 인과관계가 없는 문제를 다루므로 **무방향** 에지를 사용



(a) 베이저안 네트워크(방향 그래프)



(b) 마르코프 랜덤필드(무방향 그래프)

그림 10-1 확률 그래피컬 모델

10.1.2 그래프 분해와 확률 표현

■ 그래프 $G = \{X, E\}$

- 노드의 집합 $X = \{x_1, x_2, \dots, x_n\}$
- 에지의 집합 $E = \{e_1, e_2, \dots, e_m\}$

■ 완전 그래프 예, [그림 10-2]

- 결합확률 $P(\mathbf{x}) = P(x_1, x_2, x_3)$ 을 부여해야 함
- 확률변수가 가질 수 있는 값이 $x_1 \in \{smoking, non_smoking\}$, $x_2 \in \{lung_cancer, not_lung_cancer\}$, $x_3 \in \{positive, negative\}$ 라면 8개(2^3) 상태에 대해 확률값을 지정해야 함




그림 10-2 세 확률변수의 완전 그래프(결합 확률 필요)

$$\begin{aligned} P(smoking, lung_cancer, positive) &= 0.02, & P(non_smoking, lung_cancer, positive) &= 0.01, \\ P(smoking, lung_cancer, negative) &= 0.01, & P(non_smoking, lung_cancer, negative) &= 0.01, \\ P(smoking, not_lung_cancer, positive) &= 0.03, & P(non_smoking, not_lung_cancer, positive) &= 0.02, \\ P(smoking, not_lung_cancer, negative) &= 0.20, & P(non_smoking, not_lung_cancer, negative) &= 0.70 \end{aligned}$$

10.1.2 그래프 분해와 확률 표현

■ 결합확률

- 완벽한 확률 정보로서 모든 확률 추론 가능
 - 예, 엑스레이가 양성일 때 폐암 확률은?
 - 예, 흡연자의 폐암 확률은?
- 결합확률을 알아내는 일은 차원의 저주
 - n 개 확률변수가 있고, 각각 q 개의 값을 가진다면 총 $q^n - 1$ 개의 확률을 알아내야 함

마지막 한 개는 확률 총합인 1에서 빼면 알 수 있기 때문

■ 그래프 분해

- 직접 상호작용하는 확률변수만 에지로 연결함(확률 그래피컬 모델의 핵심 아이디어)
 - 베이지안 네트워크는 직접 인과관계가 있는 변수만 방향 에지로 연결
 - 마르코프 랜덤필드는 이웃한 변수만 무방향 에지로 연결
- 결합확률을 알아낼 필요가 없어지고, 분해된 그래프에서 부분집합의 확률분포만 알아내면 됨
- 에지 연결이 없는 노드는 중간 노드를 통해 상호작용을 함(예, 흡연과 엑스레이는 폐암을 통해 상호작용)

8개의 확률변수에 각각 옵션이 4씩이면 $4^8 - 1$ 개를 알아야하는데 65535개를 어느 세월에 !!

10.1.2 그래프 분해와 확률 표현

– 결합 확률

- A와 B 사건이 동시에 발생하는 확률, 조건부 확률의 수식으로 유도할 수 있음
- 이를 '곱셈 법칙'이라고 한다.
- 만약, 각 사건 A와 B가 독립이라면, $P[A|B]=P(A)$ 이 되므로 위의 곱셈 법칙에 대입하면, $P[B] \times P[A]=P(A \cap B)$ 가 성립한다.

$$P[A|B] = \frac{P[A \cap B]}{P[B]}$$

– 체인 규칙(chain rule)

- 각 사건 이 일어날 확률은 조건부 확률과 결합 확률을 이용하여 연쇄적인(chain) 조건부 확률의 곱의 표현식으로 표현할 수 있다.
- 이를 '체인 규칙'이라고 한다.

$$P(A_1, A_2, A_3, A_4, \dots, A_n)$$

$$= P(A_1 | A_2, A_3, A_4, \dots, A_n) \times P(A_2 | A_3, A_4, \dots, A_n) \times \dots \times P(A_{n-1} | A_n) \times P(A_n)$$

$$P(A_2|A_1) = \frac{P(A_1 \cap A_2)}{P(A_1)} \Rightarrow P(A_1 \cap A_2) = P(A_1) \cdot P(A_2|A_1)$$

$$\begin{aligned} P(A_3|A_1 \cap A_2) &= \frac{P(A_1 \cap A_2 \cap A_3)}{P(A_1 \cap A_2)} \\ \Rightarrow P(A_1 \cap A_2 \cap A_3) &= P(A_1 \cap A_2) \cdot P(A_3|A_1 \cap A_2) \\ \Leftrightarrow P(A_1 \cap A_2 \cap A_3) &= P(A_1) \cdot P(A_2|A_1) \cdot P(A_3|A_1 \cap A_2) \end{aligned}$$

10.2 베이지안 네트워크

■ 베이지안 네트워크의 장점

- 베이지안 네트워크는 데이터로부터 확률 추정
- 확률변수 사이의 인과관계를 조건부 확률로 표현하므로 불완전 데이터를 처리할 수 있음(일부 확률변수를 관찰했을 때 나머지 변수 중 관심 있는 것의 확률을 계산할 수 있음)

■ 세 가지 주요 문제

- 구조 학습^{structure learning}: [그림 10-1(a)]와 같은 그래프 구조를 만드는 작업이다. 확률변수는 **사람이 결정**해야 하며, 확률변수가 정해지면 이들 간의 인과관계는 사람이 지정하거나 데이터로부터 자동으로 알아낼 수 있다.
- 확률 학습^{probability learning}: 노드 또는 노드와 노드 사이에 확률을 부여하는 작업이다. 부모가 없는 루트 노드는 사전 확률, 부모가 있는 노드는 조건부 확률을 알아낸다.
- 확률 추론^{probabilistic inference}: 구조 학습과 확률 학습을 마친 후 테스트 단계 또는 현장 설치 후 수행하는 작업이다. 흡연자의 폐암 확률을 알아내는 것과 같은 각종 질문에 대한 확률을 추정하는 일이다.

10.2.1 간단한 예제

예제 10-1 베이زي안 네트워크로 폐암 진단

병원에서는 폐암 진단을 위해 엑스레이 사진을 찍는다. 이때 폐암과 엑스레이를 확률변수로 뽑고, 각각을 x_1 과 x_2 로 표기하자. 자칫 엑스레이 결과를 보고 폐암을 진단하므로 엑스레이 → 폐암이라는 인과관계를 맺으려 할 수 있는데, 자연계 현상에서는 폐암 여부가 엑스레이 결과를 좌우하므로 [그림 10-3]과 같이 폐암 → 엑스레이라고 표현해야 한다.

청정지역으로 유명한 마을에 사는 길동은 정기건강검진을 하던 중 엑스레이에서 양성 반응이 나타났다. 공황상태에 빠진 길동은 문득 기계 학습 과목에서 배운 베이زي안 네트워크 이론이 떠올랐다. [그림 10-3]과 같이 노드 2개를

가진 베이زي안 네트워크의 구조를 설계한 다음, 통계청의 의료 데이터를 열람하여 자신이 사는 지역의 폐암 환자 비율이 0.001, 즉 1천 명당 1명꼴이라는 사실을 알아낸다. 또한, 의사로부터 엑스레이는 완벽하지 않다는 말을 듣고, 폐암 환자 중 60%만 양성 반응이 나타나며 간혹 폐암이 아닌 정상인 100명에 2명꼴로 양성 반응이 나타난다는 설명을 들었다. 즉, 참 긍정률(true positive rate)이 0.6이고 참 부정률(false negative rate)이 0.98이다.¹ 길동은 이 통계 데이터를 그래프에 추가하여 [그림 10-3]의 베이زي안 네트워크를 완성하였다.



$$P(\text{lung_cancer}) = 0.001$$
$$P(\text{not_lung_cancer}) = 0.999$$

$$P(\text{positive}|\text{lung_cancer}) = 0.6$$
$$P(\text{negative}|\text{lung_cancer}) = 0.4$$
$$P(\text{positive}|\text{not_lung_cancer}) = 0.02$$
$$P(\text{negative}|\text{not_lung_cancer}) = 0.98$$

그림 10-3 노드가 2개인 베이زي안 네트워크

10.2.1 간단한 예제

길동은 자신이 알고 싶어하는 확률, 즉 엑스레이가 양성인 조건에서 폐암일 확률을 수식 $P(x_1 = \text{lung_cancer} | x_2 = \text{positive})$ 로 표현하였다. 그리고 2장의 식 (2.26)의 베이즈 정리를 이용하여 다음과 같이 계산하였다.

$$\begin{aligned} P(\text{lung_cancer} | \text{positive}) &= \frac{P(\text{positive} | \text{lung_cancer})P(\text{lung_cancer})}{P(\text{positive})} \\ &= \frac{P(\text{positive} | \text{lung_cancer})P(\text{lung_cancer})}{P(\text{positive} | \text{lung_cancer})P(\text{lung_cancer}) + P(\text{positive} | \text{not_lung_cancer})P(\text{not_lung_cancer})} \\ &= \frac{0.6 * 0.001}{0.6 * 0.001 + 0.02 * 0.999} = 0.029 \end{aligned}$$

길동은 엑스레이에서 양성 반응이 나타났지만 폐암일 확률은 불과 2.9%에 불과하다는 확률 추론 결과를 보고 안도하였다. 그리고 정밀 검사를 받기로 하였다.

10.2.1 간단한 예제

■ [예제 10-1]에서 세 가지 주요 문제를 풀어본 셈

- [그림 10-3]의 그래프 구조를 만드는 일은 구조 학습
- 통계청과 병원에서 확률을 수집한 일은 확률 학습
- 엑스레이에서 양성인 나타났을 때 폐암일 확률을 계산한 일은 확률 추론

■ 미세먼지에 뒤덮인 탄광 마을 주민에 적용하면,

- 탄광의 폐암 환자 비율이 0.5%라고 가정하면, 양성 반응인 사람의 폐암 확률은 13.1%

$$P(lung_cancer|positive) = \frac{0.6 * 0.005}{0.6 * 0.005 + 0.02 * 0.995} = 0.131$$

10.2.1 간단한 예제

예제 10-2 젖은 잔디

비가 오거나 스프링클러를 틀면 잔디는 젖은 상태가 된다. 비가 오면 스프링클러를 틀 필요가 없다. 이 상황을 베이저안 네트워크로 표현해 보자. 먼저 비, 스프링클러, 잔디라는 3개의 확률변수를 뽑았다고 하자. 그리고 모든 변수가 두 가지 상태만 가진다고, 즉 $\text{비} \in \{\text{rain}, \text{not_rain}\}$, $\text{스프링클러} \in \{\text{on}, \text{off}\}$, $\text{잔디} \in \{\text{wet}, \text{dry}\}$ 라 가정하자. 어느 정도 관찰한 결과, [그림 10-4]와 같은 확률을 얻었다.




그림 10-4 노드가 3개인 베이저안 네트워크

확률은 아래와 같이 표로 표현할 수도 있다. 확률의 성질에 따라 행 방향으로 값을 더하면 항상 1이 되어야 한다. 따라서, 두 번째 열을 생략하여도 된다. [그림 10-4]에서는 이 성질을 이용하여 전체 경우 중 반만 제시하였다.

비		스프링클러		잔디	
<i>rain</i>	<i>not-rain</i>	비	<i>on</i> <i>off</i>	스프링클러 비	<i>wet</i> <i>dry</i>
0.2	0.8	<i>not_rain</i>	0.4 0.6	<i>off</i> <i>not_rain</i>	0.0 1.0
		<i>rain</i>	0.01 0.99	<i>off</i> <i>rain</i>	0.8 0.2
				<i>on</i> <i>not_rain</i>	0.9 0.1
				<i>on</i> <i>rain</i>	0.99 0.01

10.2.1 간단한 예제

이제 완성된 베이지안 네트워크로부터 다양한 확률을 추론할 수 있다. 예를 들어, 비가 오지 않았는데 스프링클러가 켜져 있을 확률을 구하고자 하면 $P(\text{스프링클러} = \text{on} | \text{비} = \text{non_rain})$ 을 구하는 셈이므로 두 번째 표를 참조하여 40%라고 답하면 된다.

식 (10.1)을 적용하여 다음과 같이 결합확률을 구할 수도 있다. 총 8가지가 가능한데, 4가지만 보인다.

$$P(\text{wet}, \text{on}, \text{rain}) = P(\text{rain})P(\text{on}|\text{rain})P(\text{wet}|\text{on}, \text{rain}) = 0.2 * 0.01 * 0.99 = 0.00198$$

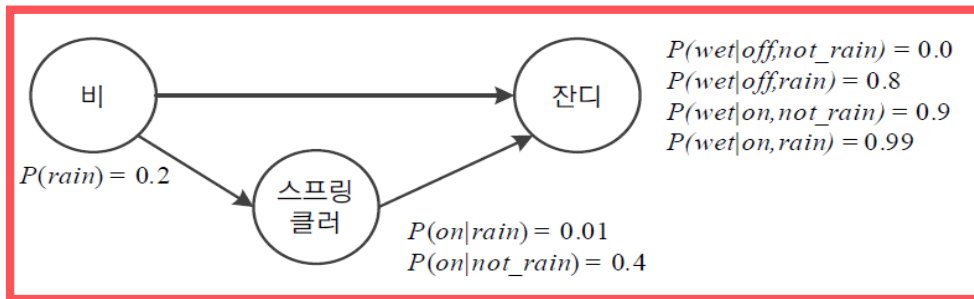
$$P(\text{wet}, \text{on}, \text{not_rain}) = P(\text{not_rain})P(\text{on}|\text{not_rain})P(\text{wet}|\text{on}, \text{not_rain}) = 0.8 * 0.4 * 0.9 = 0.288$$

$$P(\text{wet}, \text{off}, \text{rain}) = P(\text{rain})P(\text{off}|\text{rain})P(\text{wet}|\text{off}, \text{rain}) = 0.2 * 0.99 * 0.8 = 0.1584$$

$$P(\text{wet}, \text{off}, \text{not_rain}) = P(\text{not_rain})P(\text{off}|\text{not_rain})P(\text{wet}|\text{off}, \text{not_rain}) = 0.8 * 0.6 * 0.0 = 0.0$$

잔디가 젖어 있는 것을 관찰했을 때 비가 왔을 확률 $P(\text{rain}|\text{wet})$ 을 구해 보자. 다음과 같이 계산하며, 35.77%라는 것을 알 수 있다.

$$\begin{aligned} P(\text{rain}|\text{wet}) &= \frac{P(\text{rain}, \text{wet})}{P(\text{wet})} \\ &= \frac{\sum_{S \in \{\text{on}, \text{off}\}} P(\text{wet}, S, \text{rain})}{\sum_{S \in \{\text{on}, \text{off}\}} \sum_{R \in \{\text{rain}, \text{not_rain}\}} P(\text{wet}, S, R)} \\ &= \frac{P(\text{wet}, \text{on}, \text{rain}) + P(\text{wet}, \text{off}, \text{rain})}{P(\text{wet}, \text{on}, \text{rain}) + P(\text{wet}, \text{on}, \text{not_rain}) + P(\text{wet}, \text{off}, \text{rain}) + P(\text{wet}, \text{off}, \text{not_rain})} \\ &= \frac{0.00198 + 0.1584}{0.00198 + 0.288 + 0.1584 + 0.0} = 0.3577 \end{aligned}$$



10.2.2 그래프 분해


- 결합확률을 전개하면 식 (10.1)이 성립

$$\begin{aligned} P(\mathbf{x}) &= P(x_1, x_2, \dots, x_n) \\ &= P(x_1)P(x_2|x_1)P(x_3|x_2, x_1)P(x_4|x_3, x_2, x_1) \cdots P(x_n|x_{n-1}, x_{n-2}, \dots, x_1) \end{aligned} \quad (10.1)$$

- [그림 10-5]의 예제에서

- 위상 정렬한 후, 식 (10.1)을 적용하면

$$\begin{aligned} &P(\text{흡연}, \text{폐렴}, \text{폐암}, \text{피로}, \text{엑스레이}) \\ &= P(\text{흡연})P(\text{폐렴}|\text{흡연})P(\text{폐암}|\text{폐렴}, \text{흡연})P(\text{피로}|\text{폐암}, \text{폐렴}, \text{흡연}) \\ &\quad P(\text{엑스레이}|\text{피로}, \text{폐암}, \text{폐렴}, \text{흡연}) \end{aligned} \quad (10.2)$$



- 식 (10.1)과 식 (10.2)는 보편 수식 (그래프 분해를 적용하기 이전)

그림 10-5 노드가 5개인 인과관계 그래프

10.2.2 그래프 분해

■ 그래프 분해에 필요한 마르코프 조건

- 노드 x 의 부모를 y 라 할 때, y 의 값이 주어지면 x 는 비후손(후손을 제외한 모든 노드)과 조건부 독립
- 예, $P(\text{엑스레이} | \text{피로}, \text{폐암}, \text{폐렴}, \text{흡연}) = P(\text{엑스레이} | \text{폐암})$




그림 10-5 노드가 5개인 인과관계 그래프

■ 마르코프 조건을 식 (10.2)에 적용하면,

$$\begin{aligned} &P(\text{흡연}, \text{폐렴}, \text{폐암}, \text{피로}, \text{엑스레이}) \\ &= P(\text{흡연})P(\text{폐렴} | \text{흡연})P(\text{폐암} | \text{흡연})P(\text{피로} | \text{폐암}, \text{폐렴}, \text{흡연})P(\text{엑스레이} | \text{폐암}) \end{aligned}$$

$$\begin{aligned} &P(\text{흡연}, \text{폐렴}, \text{폐암}, \text{피로}, \text{엑스레이}) \\ &= P(\text{흡연})P(\text{폐렴} | \text{흡연})P(\text{폐암} | \text{폐렴}, \text{흡연})P(\text{피로} | \text{폐암}, \text{폐렴}, \text{흡연}) \\ &\quad P(\text{엑스레이} | \text{피로}, \text{폐암}, \text{폐렴}, \text{흡연}) \end{aligned}$$

10.2.2 그래프 분해

- 이렇게 유도된 식에 따라 가상의 확률을 부여해 보면,
 - [그림 10-6]의 베이지안 네트워크가 됨

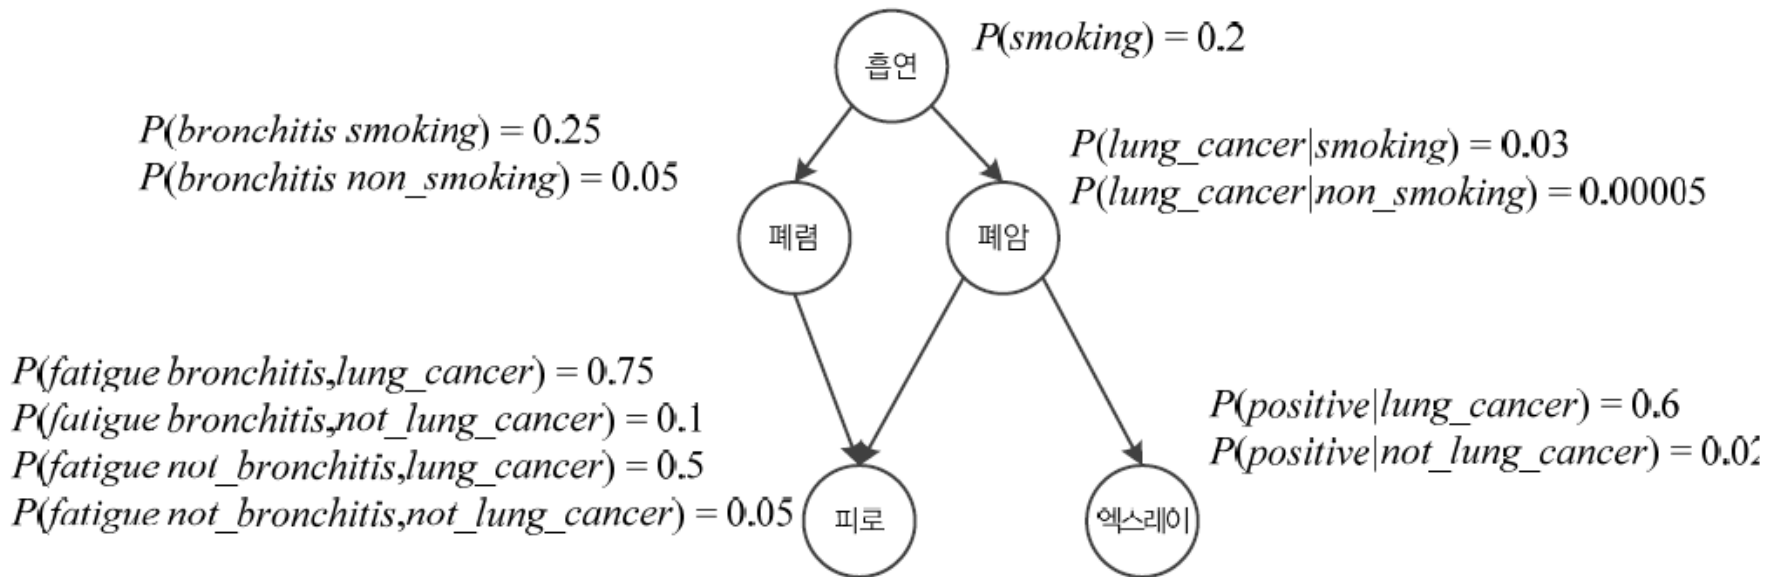


그림 10-6 베이지안 네트워크

10.2.2 그래프 분해

■ 그래프 분해로 확률 학습이 쉬워짐

- 부모 자식 사이에만 확률을 부여하면 됨

베이지안 네트워크에 확률을 부여하는 방법: 부모가 없는 루트 노드에는 사전 확률을 부여하고, 부모가 있는 노드에는 부모와 자식 사이로 한정하여 조건부 확률을 부여한다.

■ 확률 학습 수행

- 해당 분야 전문가가 경험이나 보유한 데이터를 기반으로 부여
- 또는 훈련집합을 가지고 자동 학습

■ 구조 학습과 확률 학습을 통해 베이지안 네트워크를 완성한 다음, 확률 추론을 수행

pgmpy

- pgmpy is a library for probabilistic graphical models in Python.
- Bayesian Network
(<https://pgmpy.org/models/bayesiannetwork.html>)